BNP PARIBAS COE DEVOPS · 13 OCTOBRE 2026

Nos workflows agentiques s'améliorent-ils vraiment ?

D'une vague impression à une mesure fiable.

Jean-Louis Rigau · Manufacture

Vous ajoutez un skill...
Vous faites relire le travail d'un agent par un autre...
Vous changez de modèle...

Et vous trouvez que ça s'améliore !

Mais comment en être sûr ?



Jean-Louis Rigau

Vibe coder & AI-native advisor @ Manufacture

J'aide les entreprises à construire des organisations agentiques, de l'outillage au delivery, en mesurant ce que les agents changent vraiment.

LinkedIn

04 On ne sait pas prouver, alors on mesure

2003 · L'IDÉAL THÉORIQUE

Machine de Gödel

Jürgen Schmidhuber imagine une machine qui réécrit son propre code, mais seulement si elle **prouve** que c'est mieux.

→

AUJOURD'HUI · EN PRATIQUE

Une approche empirique

Prouver, on ne sait pas. Alors on **mesure** chaque changement sur de vrais essais, et on ne garde que ce qui améliore vraiment le résultat.

Une mesure ne prouve rien… mais elle remplace les impressions par des faits.

05

Les benchmarks mesurent les modèles, pas nos workflows

2021

HumanEval

Du code qui passe des tests.

2023

SWE-bench

De vraies issues, dans des dépôts publics.

2024

AI Agents That Matter

Mesurer aussi le coût et la reproductibilité.

2025

SWE-bench Pro

Des tâches longues, sur 41 dépôts actifs.

2025

Étude METR

Des devs 19 % plus lents avec l'IA, qui se croyaient 20 % plus rapides.

2026

Effet scaffold

Le harnais, une variable cachée des classements.

Les benchmarks le montrent : le workflow compte. Mais pour savoir si le nôtre s'améliore, il faut le mesurer sur nos propres tâches.

Ouverture

PARTIE 1

La mesure

préparer

Une application, le choix d'un use case, des critères d'acceptation.

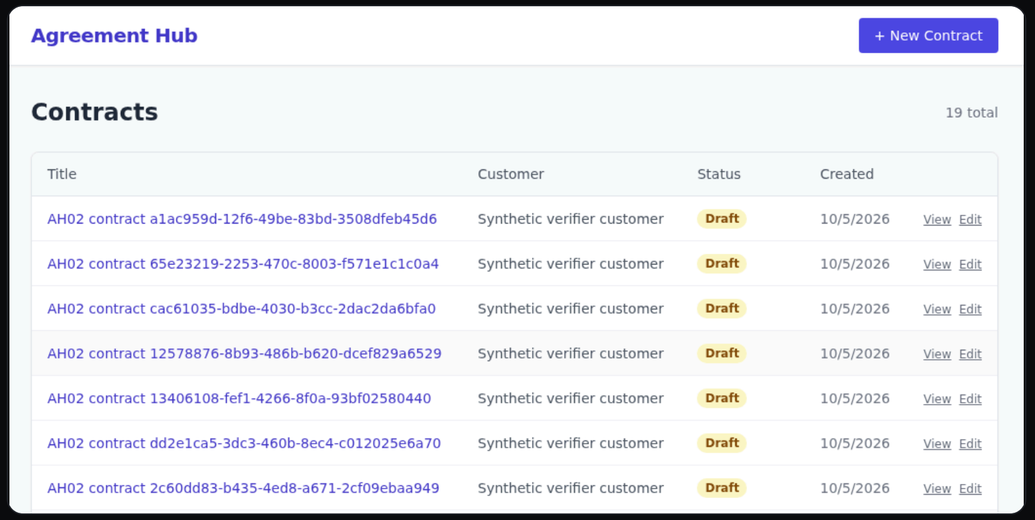
mesurer

S'outiller, observer et comparer chaque run.

évaluer

Se poser les bonnes questions.

07 Une application et un use case comme terrain de jeu



Agreement Hub au départ · React, Express, SQLite, 24 tests (TU + Playwright)

LE USE CASE · AH02

Une bibliothèque de clauses : les créer, les archiver, les insérer dans un contrat avec leur provenance.

EXIGENCE CLÉ

Aucun doublon, même en cas de retry.

19 CRITÈRES D'ACCEPTATION

L0	1	le CRUD des contrats existant reste intact
L1	8	créer, lister, éditer une clause, ses révisions
L2	3	archiver, restaurer, filtrer
L3	7	prévisualiser, insérer avec provenance, retry sans doublon

Ce que « réussir » veut dire est fixé avant le premier run, et vérifié comme un utilisateur.

08 Un skill et un workflow comme point de départ

LE WORKFLOW DE DÉPART



4 CONFIGURATIONS COMPARÉES

C0 agent seul	**CB** + skill
CR + review	**CBR** les deux

PUIS ITÉRER SUR LE SKILL

Un skill qui aide l'agent à transformer l'énoncé en vérifications observables.

skill v1

Une matrice de vérification

→ aucun gain

skill v2

Des contre-exemples ciblés

→ retry testé, aucun gain

skill v3

Exécuter, pas cocher

→ testé seulement en pilote

Écrire, mesurer, corriger, recommencer : un skill se construit par itérations.

09

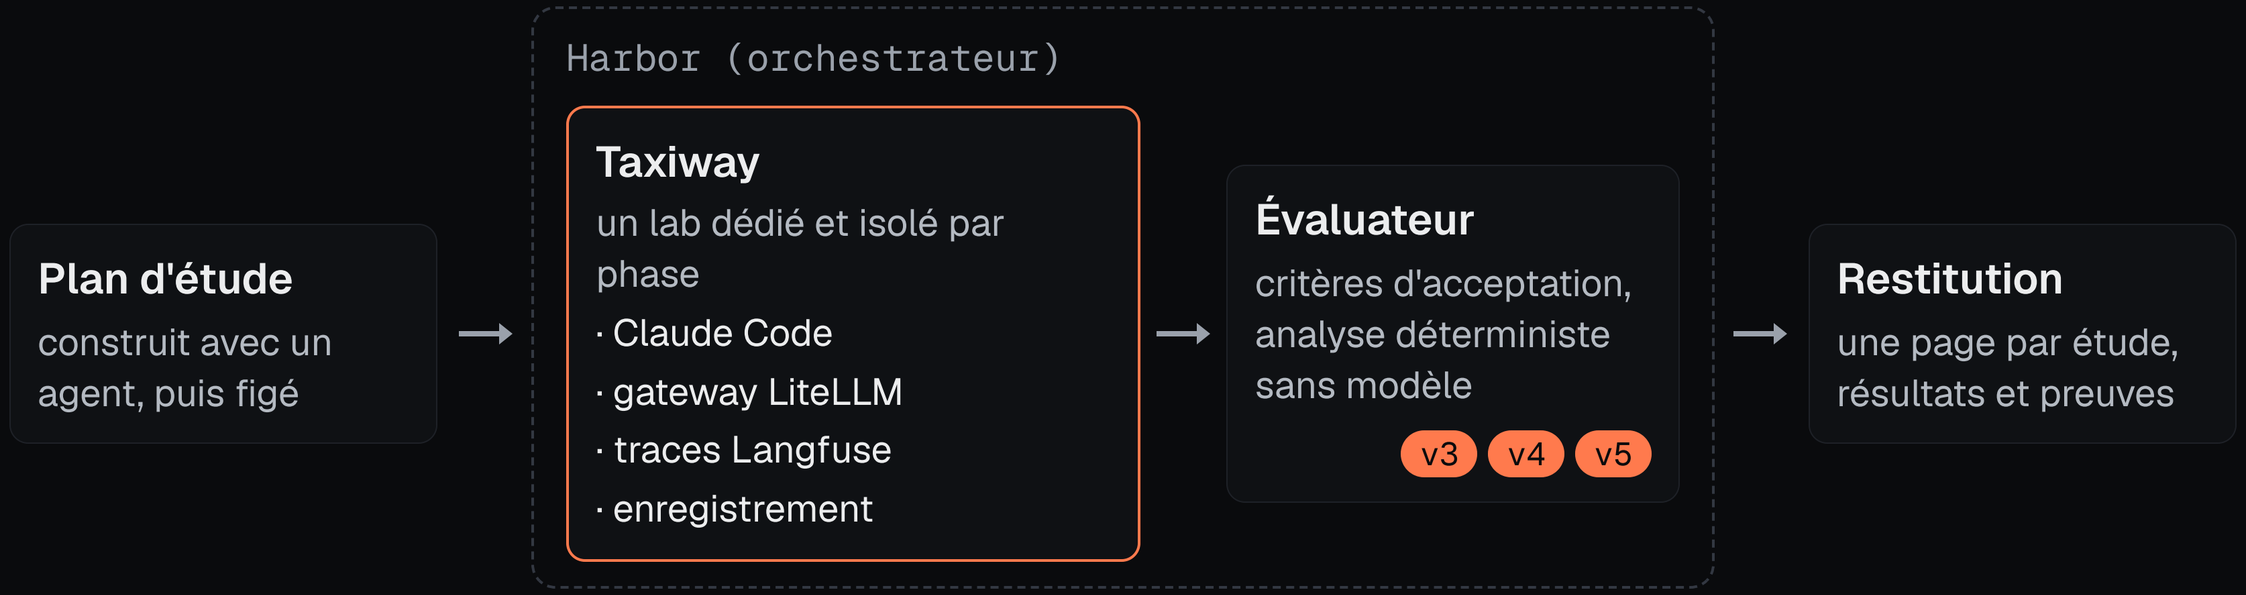
La chaîne de mesure, du plan au résultat

étude r07a — le skill et la review font-ils mieux que l'agent seul ?

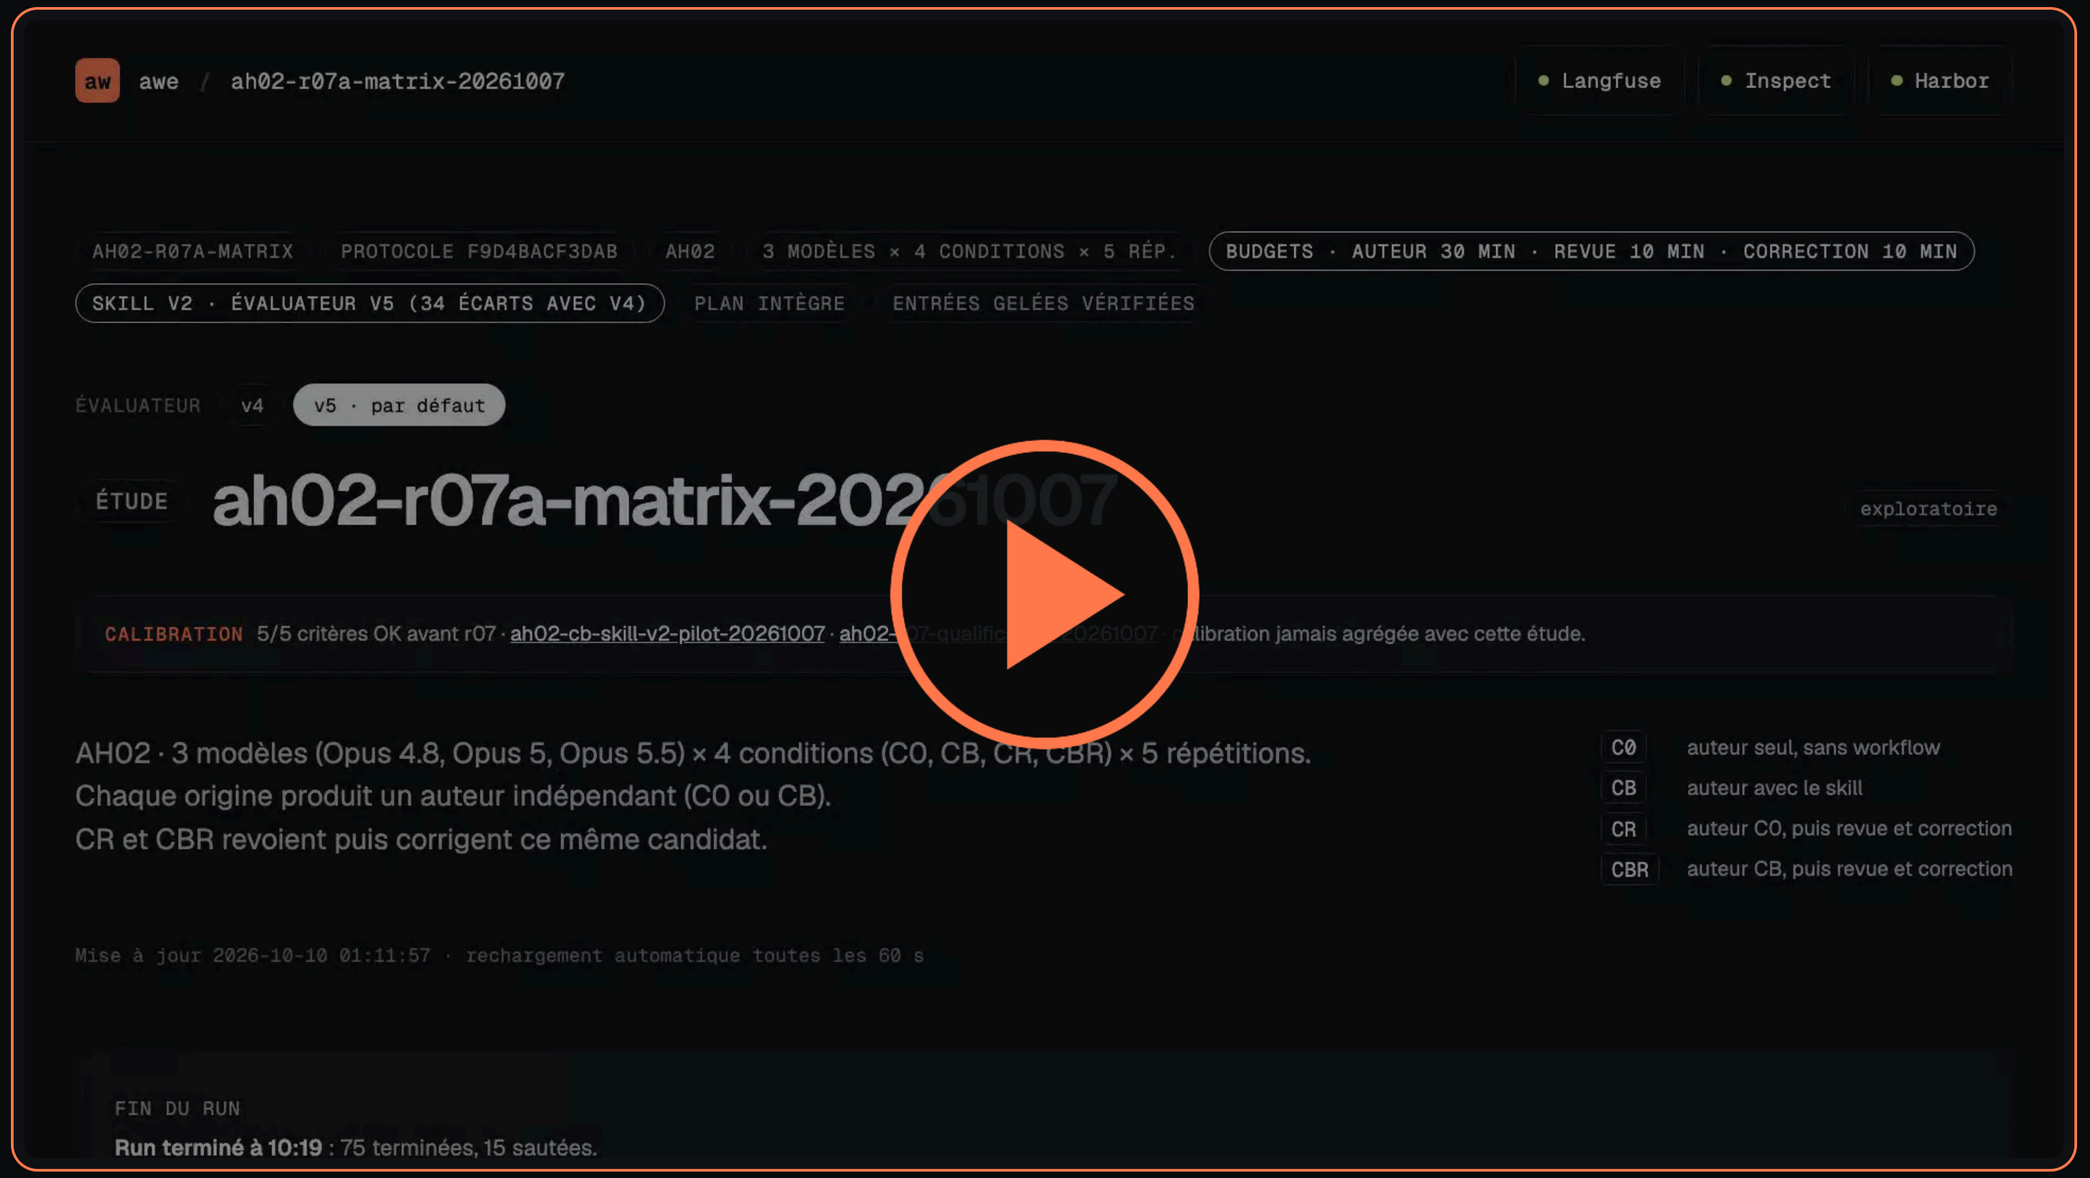
3 × 4 modèles × workflows

× 5 répétitions

60 résultats notés



▶ VIDÉO · Une étude : le plan, un run, son verdict, son enregistrement



QUESTION 1 · MON SKILL ET MA REVIEW FONT-ILS MIEUX ?

11 Presque pas, et ce n'est pas gratuit

≈ 0
critère gagné avec le skill, v1 comme v2

0 à 2 / 5
essais réparés par la review, sans régression

+2,7 à 3,7 $
par essai pour la review, chez Opus 4.8 et Opus 5

	C0 agent seul	CB + skill	CR + review	CBR les deux
Opus 4.8	**0/5** 5,65 $	**0/5** 5,95 $	**0/5** 8,38 $	**0/5** 8,69 $
Opus 5	**0/5** 7,26 $	**0/5** 7,84 $	**2/5** 10,62 $	**2/5** 11,56 $
Opus 5.5	**4/5** 2,60 $	**2/5** 2,92 $	**4/5** 3,11 $	**2/5** 3,47 $

étude r07a

évaluateur v5. Essais réussis sur 5, puis coût moyen par essai, revue et correction comprises.

QUESTION 2 · POURQUOI SI PEU ?

12 Le skill change les tests, la review ne voit pas ses angles morts

LE SKILL

12/15
essais avec skill testent le retry après une modification (0/15 sans)

0/3
réussissent quand le test attend la mauvaise valeur

Il fait tester le bon cas. Mais si le résultat attendu est faux, le test valide le bug.

LA REVIEW

12/16
bugs de retry signalés

0/22
historiques bloqués signalés quand le modèle relit son propre code

Un défaut qu'on montre au relecteur est presque toujours réparé. Un défaut qu'il doit trouver seul, 1 fois sur 9.

QUESTION 3 · ET UN WORKFLOW PUBLIC, PRÊT À L'EMPLOI ?

13 Superpowers : installé ne veut pas dire suivi

SP · installé tel quel

L'agent choisit de s'en servir. Opus 4.8 n'invoque aucun skill dans 2 essais sur 10.

SPS · chaîne complète demandée

Seul Opus 5.5 la suit en entier, 7 fois sur 10.

étude r08 un essai par ligne

MODÈLE	CONDITION	VERDICT	ÉTAPES DE LA CHAÎNE
claude-opus-5 high	SPS	échoué 17 critères timeout	BR › WT › WP › EX › VER · exécution par sous-agents manque CR FIN · CR via revue finale SDD TDD : consigne aux implémenteurs
claude-opus-5-5 high	SPS	réussi tous les critères	BR › WT › WP › EX › TDD › CR › RCR › VER › FIN · exécution par sous-agents chaîne complète

QUESTION 3 · ET UN WORKFLOW PUBLIC, PRÊT À L'EMPLOI ?

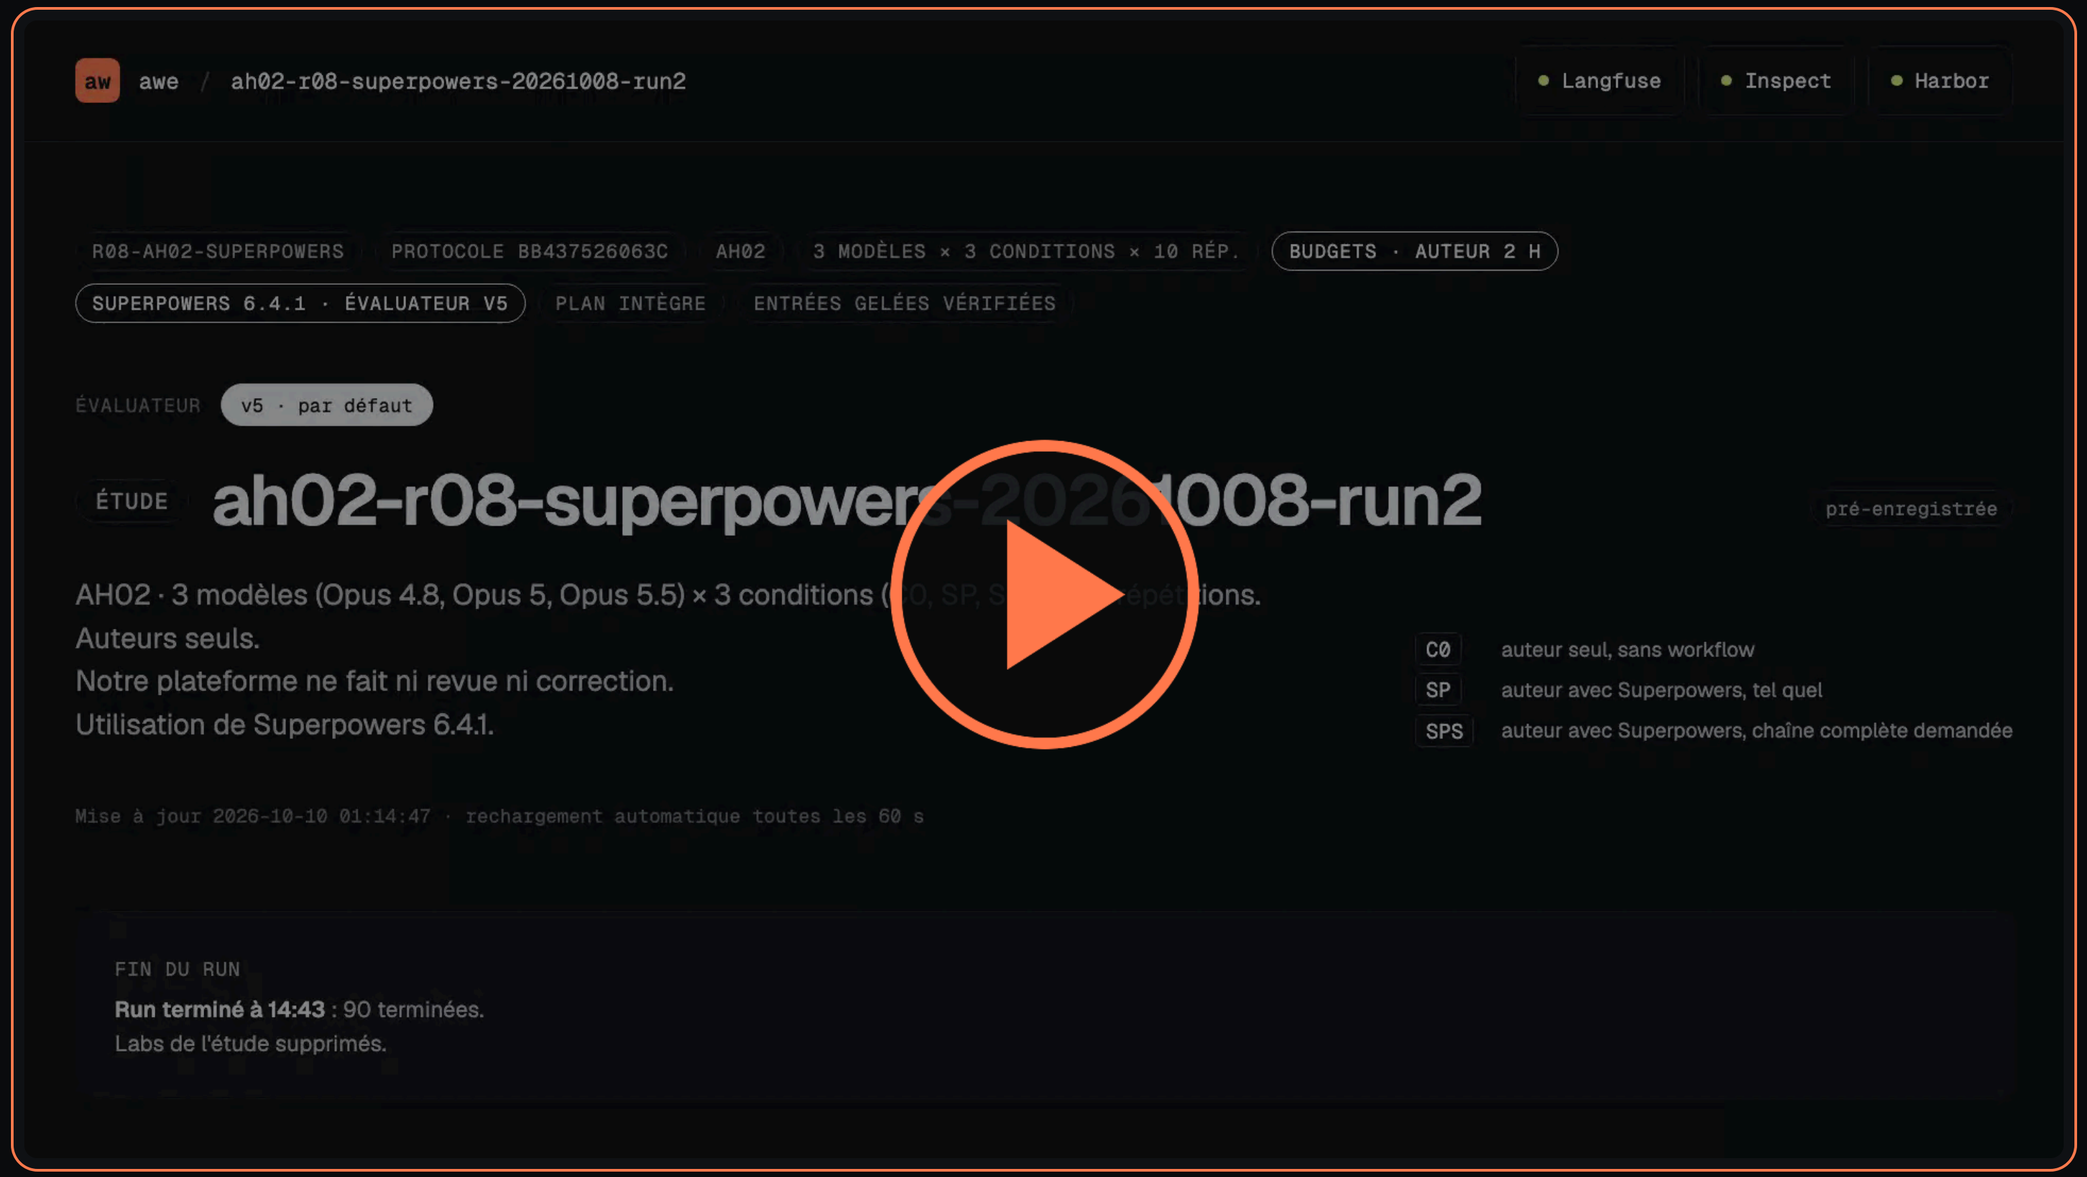
14 Superpowers ne remplace pas le modèle

étude r08 essais qui passent tous les critères, coût moyen par essai · 90 essais · plan d'analyse écrit avant les résultats

	sans workflow	SP · tel quel	SPS · chaîne complète
Opus 5.5	7/10 · 2,9 $	8/10 · 5,5 $	10/10 · 13,5 $
Opus 5	0/10 · 7,7 $	0/10 · 23,2 $	0/10 · 22,9 $ · 10 timeouts
Opus 4.8	0/10 · 5,3 $	0/10 · 11,4 $	0/10 · 26,7 $

Aucun gain détecté sur le taux de réussite, pour 2 à 5 fois le coût. Un critère, le retry qui renvoie la réponse d'origine, bloque Opus 4.8 et Opus 5 dans les 60 essais.

▶ VIDÉO · Superpowers : la chaîne de skills, essai par essai



QUESTION 4 · ET SI JE CHANGE DE USE CASE ?

16 Un nouveau use case, tout est à re-mesurer

AH03 circuit d'approbation des contrats (même application, évaluateur dédié)

	réussites	ce qui bloque
Opus 5.5	4 sur 5	réponse perdue, 1 fois
Opus 4.8	2 sur 3	soumission, double clic
Opus 5	0 sur 3	réponse perdue, nouvelle soumission

Sur AH02 : Opus 4.8 et Opus 5 à égalité, 0/10.
Sur AH03 : Opus 4.8 passe devant Opus 5.

Le point dur reste le même : les chemins d'erreur. Mais les résultats d'un use case ne se transposent pas à un autre. Il faut re-mesurer, avec un évaluateur écrit pour ce use case.

PARTIE 2

La difficulté à mesurer

construire

L'énoncé, une implémentation de référence, puis éprouver l'évaluateur.

se tromper

Un code conforme refusé, une faute acceptée.

s'améliorer

Sans regarder les scores. Chaque erreur ramène au début.

18

Avant de noter, on éprouve son évaluateur

AH02 évaluateurs v4 et v5

CONCEVOIR

Un énoncé public, une implémentation de référence qui le respecte, et un évaluateur externe. Chaque contrôle cite sa phrase de l'énoncé.

ÉPROUVER

Calibration

26

contrôles de variantes correctes et de fautes

Mutation

36/36

mutants du code de référence détectés

Autres modèles

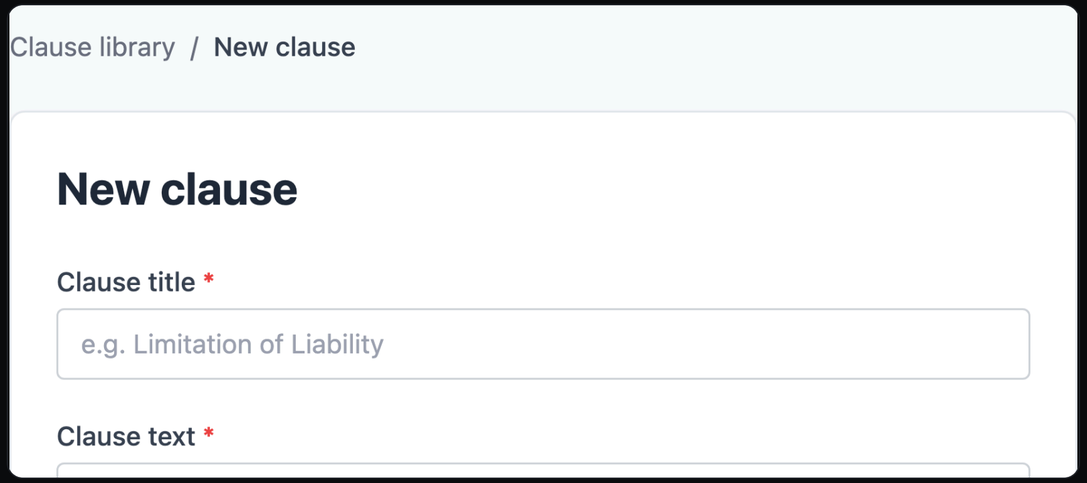
127

trouvailles en 9 sessions

Aucune méthode ne suffit seule : chacune couvre les angles morts des autres.

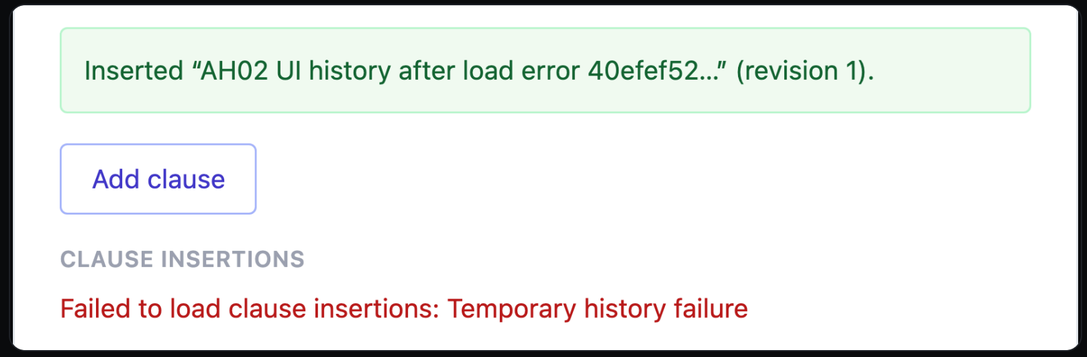
L'évaluateur se trompe, dans les deux sens

IL REFUSE UN CODE CONFORME



« Clause title * » refusé à cause de l'astérisque : 36 échecs comptés à tort.

IL LAISSE PASSER UNE FAUTE



L'historique reste bloqué après une erreur de chargement. Invisible jusqu'à ce que d'autres modèles cherchent les failles de l'évaluateur.

Un score ne dit pas qui s'est trompé : l'agent ou l'évaluateur.

20 Améliorer l'évaluateur, sans toucher aux résultats

plan figé
énoncé, prompts, skill et évaluateur, empreinte vérifiée

verdict caché
les agents ne voient jamais l'évaluateur

rien d'écrasé
chaque version de l'évaluateur garde ses verdicts

une seule étude
jamais deux protocoles mélangés

pannes écartées
rejouées sans regarder le score

```
● Agent "Implement Task 5: insertion UI" failed: Agent terminated early due to an API
error: API Error: Server is temporarily limiting requests (not your usage limit) ·
litellm.RateLimitError: AnthropicException -
{"type":"error","error":{"type":"rate_limit_error","message":"This request would exceed
your account's rate limit. Please try again
later."},"request_id":"req_011Cfqii95tiJUwSuJV54aFK"}. Received Model
Group=claude-sonnet-5-5
Available Model Group Fallbacks=None (error type rate_limit, HTTP 429, model sent to the
API: claude-sonnet-5-5)
```

Une panne d'API ressemble à un agent qui échoue.

Un score ne se négocie pas : ni l'agent mesuré, ni celui qui mesure ne doit pouvoir l'arranger.

21 Changer l'évaluateur, c'est changer la conclusion

TROIS VERSIONS DE L'ÉVALUATEUR

évaluateur v3
Il laissait passer des fautes

évaluateur v4
Il refusait un code conforme

évaluateur v5
Il voit l'historique bloqué

étude r07a

MÊMES CANDIDATS, RIEN DE RELANCÉ · LA CONCLUSION BOUGE

	évaluateur v4	évaluateur v5
Opus 5.5 sans skill : essais qui passent tous les critères	5/5	4/5
Opus 5.5 avec skill : essais qui passent tous les critères	5/5	2/5
verdict sur le skill	neutre	défavorable

Le v5 voit l'historique bloqué, plus fréquent avec le skill.

Un résultat n'est fiable que si l'évaluateur l'est.

▶ VIDÉO · La même étude notée par l'évaluateur v4, puis v5



À RETENIR

Ce que ça change pour vos workflows

Mesurez sur vos tâches

Le benchmark ne dit rien de votre workflow.

Un skill doit gagner sa place

Il peut coûter sans rien apporter.

Re-mesurez à chaque changement

Nouveau modèle, nouveau use case : ce qui aidait peut nuire.

Évaluez votre évaluateur

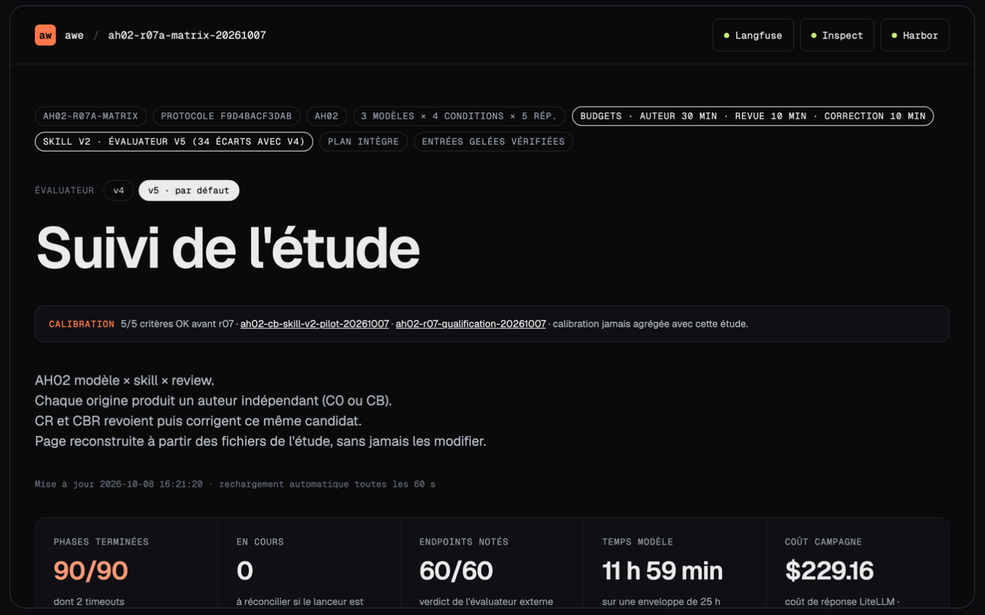
Il se trompe aussi, dans les deux sens.

ET DEMAIN

Cette boucle, mesurer puis garder ce qui fait ses preuves, des agents la feront seuls. Il leur faudra le même évaluateur éprouvé et les mêmes garde-fous.

MERCI

Des questions ?



Prochainement inclus dans Taxiway

taxiway.sh

Jean-Louis Rigau · Manufacture